

①

Etapas 2 - Propto 3

Eduardo Gebara
Daniel Ruhman

$$a) \hat{y} = \hat{\beta}_0 + \hat{\beta}_1 \cdot x$$

$$y_i = \hat{y}_i + \varepsilon_i = \hat{\beta}_0 + \hat{\beta}_1 \cdot x_i + \varepsilon_i, \quad i = 1, 2, \dots, n$$

$$\varepsilon_i = y_i - \hat{y}_i$$

Soma dos Erros Quadrados:

$$SEQ = \sum_{i=1}^n \varepsilon_i^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n (y_i - \hat{\beta}_0 + \hat{\beta}_1 \cdot x_i)^2$$

derivar para minimizar a soma dos erros quadrados:

$$(1) \frac{\partial SEQ}{\partial \beta_0} = 0 \quad \text{e} \quad (2) \frac{\partial SEQ}{\partial \beta_1} = 0$$

$$(1) \left. \frac{\partial SEQ}{\partial \beta_0} \right|_{\hat{\beta}_0, \hat{\beta}_1} = -2 \cdot \sum_{i=1}^n (y_i - \hat{\beta}_0 + \hat{\beta}_1 \cdot x_i) = 0$$

$$\left. \frac{\partial SEQ}{\partial \beta_0} \right|_{\hat{\beta}_0, \hat{\beta}_1} = -2 \left[\sum_{i=1}^n y_i - n \cdot \hat{\beta}_0 - \hat{\beta}_1 \cdot \sum_{i=1}^n x_i \right] = 0$$

$$\sum_{i=1}^n y_i - n \cdot \hat{\beta}_0 - \hat{\beta}_1 \cdot \sum_{i=1}^n x_i = 0$$

$$\hat{\beta}_0 = \frac{1}{n} \sum_{i=1}^n y_i - \hat{\beta}_1 \cdot \frac{1}{n} \cdot \sum_{i=1}^n x_i$$

② $\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \cdot \bar{x}$, tal que $\bar{x} = \frac{\sum_{i=1}^n x_i}{n}$ e $\bar{y} = \frac{\sum_{i=1}^n y_i}{n}$

(2)

$$\frac{\partial SEQ}{\partial \beta_1} \Big|_{\hat{\beta}_0, \hat{\beta}_1} = -2 \cdot \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) x_i = 0$$

$$\frac{\partial SEQ}{\partial \beta_1} \Big|_{\hat{\beta}_0, \hat{\beta}_1} = -2 \cdot \left[\sum_{i=1}^n x_i y_i - \hat{\beta}_0 \sum_{i=1}^n x_i - \hat{\beta}_1 \sum_{i=1}^n (x_i)^2 \right] = 0$$

$$\sum_{i=1}^n x_i y_i - (\bar{y} - \hat{\beta}_1 \bar{x}) \cdot \sum_{i=1}^n x_i - \hat{\beta}_1 \sum_{i=1}^n (x_i)^2 = 0$$

$$\sum_{i=1}^n x_i y_i + \hat{\beta}_1 (\bar{x})^2 \cdot n - \bar{y} \bar{x} \cdot n - \hat{\beta}_1 \sum_{i=1}^n (x_i)^2 = 0$$

$$\sum_{i=1}^n x_i y_i - \bar{y} \bar{x} \cdot n = \hat{\beta}_1 \cdot \sum_{i=1}^n (x_i)^2 - \hat{\beta}_1 \cdot (\bar{x})^2 \cdot n$$

$$\sum_{i=1}^n x_i y_i - \bar{y} \bar{x} \cdot n = \hat{\beta}_1 \left(\sum_{i=1}^n (x_i)^2 - (\bar{x})^2 \cdot n \right)$$

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n x_i y_i - \bar{y} \bar{x} \cdot n}{\sum_{i=1}^n (x_i)^2 - (\bar{x})^2 \cdot n}$$

③

b) A supervisão feita é a de que podemos compreender um conjunto de dados, normalmente representados no plano cartesiano por um "scatter plot", por uma reta (no caso da regressão linear), usando o método dos mínimos quadrados.

O erro pode ser representado através da soma dos erros quadrados:

$$SEQ = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n (\epsilon_i)^2, \text{ onde } \hat{y}_i \text{ é o valor estimado de } y_i$$

distância
entre ponto
e valor correspondente
no eixo y

c) a estimativa da variância σ^2 se dá por:

$$\hat{\sigma}^2 = \frac{SEQ}{n-2}, \text{ tal que } n \text{ é o número de pares de pontos } (x_i, y_i)$$

É importante também incluir o coeficiente de determinação (R^2), que é uma medida de ajuste do modelo linear em relação aos valores observados.

$$R^2 = 1 - \frac{SEQ}{SQT}, \text{ tal que } SQT \text{ é a soma dos quadrados totais, dada por } SQT = S_{yy} = \sum_{i=1}^n (y_i - \bar{y})^2$$

④ Vale ressaltar que $0 \leq R^2 \leq 1$ e esse valor indica, em porcentagem, o quanto o modelo consegue explicar os valores observados.

c) Teste de Hipóteses

(nula) $H_0: \beta_1 = \beta_{1,0}$

(alternativa) $H_1: \beta_1 \neq \beta_{1,0}$, em que $\beta_{1,0}$ é uma constante

Um caso especial desse teste de hipóteses é quando $\beta_{1,0} = 0$:

$$H_0: \beta_1 = 0$$

$$H_1: \beta_1 \neq 0$$

Não rejeitar H_0 significa dizer que não há relação linear entre as variáveis X e Y . Se H_0 for rejeitada, quer dizer que X explica a variabilidade de Y e portanto há correlação entre as variáveis estudadas.

d) Sim, é possível. A mudança ocorreria na quantidade de variáveis regressoras que são as dependentes de uma variável resposta, e de suas respectivas derivadas parciais. A equação $y_i = \beta_0 + \beta_1 x_i$ da reg. são linhas simples precisava ser modificada para incluir as demais variáveis, o que impacta todo o processo matemático do item a).

⑤

A equação para m variáveis fica como a seguir:

$$y_i = \beta_0 + \beta_1 \cdot x_{i1} + \beta_2 \cdot x_{i2} + \dots + \beta_m \cdot x_{im} + \epsilon_i$$

Em relação a suposição do modelo, quanto maior o número de variáveis, mais perto chegamos de um modelo que se ajuste melhor aos dados.

Por fim, em relação ao teste de hipótese, quanto maior o número de variáveis, maior será o erro acumulado nas variáveis dependentes ($x_{i1}, x_{i2}, \dots, x_{im}$) e maior a chance de H_0 ser rejeitada.

$$H_0: \beta_1 = \beta_2 = \dots = \beta_m = 0$$

$$H_1: \text{pelo menos um } \beta \neq 0$$